Mode Selection

Mode Selection

Mode Selection は、解釈された意図とタスクに基づいて、**LLM をどのような認知・実行モードで動かすかを決める構造**である。
ここでいうモードとは、単なる出力スタイルではなく、**情報取得の要否、推論の深さ、外部ツール依存度、比較や生成の優先度、停止条件の傾向**まで含む処理運転形態である。

要点

- 同じ入力でも、選ぶモードによって処理の進み方は大きく変わる
- Mode Selection は、Task Routing で決まった処理ラインをさらに具体的な運転状態へ落とし込む
- モードは「何をするか」ではなく「どう動くか」を決める
- 良いモード選択は、過不足ない深さ・速度・正確性・形式適合性を生む
- モードを誤ると、正しいルートでも応答品質が崩れる

なぜ必要か

たとえば「この件を教えてください」という依頼でも、

- 安定知識なら直答でよい
- 最新情報なら検索前提で動くべき
- ファイルが主根拠なら file-grounded にすべき
- 比較なら比較軸生成を先に走らせるべき
- 成果物生成なら構造化テンプレートを優先すべき

この差は、単なるタスク分類では足りない。
同じ「説明」でも、

- 短く答える説明
- 出典付き説明
- 比較を含む説明
- 生成物の前置きとしての説明

では内部運転が違う。

そのため、処理ラインの中での**実際の走り方**を決める Mode Selection が必要となる。

中核機能

1. Mode Requirement Detection

今回のタスクが、どのような処理モードを必要とするかを判定する。

判断材料:

- 最新性の要否
- 根拠の強さ要求
- ファイル依存の有無
- 成果物要求
- 比較や分解の必要性
- 実行操作の有無
- 安全リスク
- 簡潔さの要求

---

2. Mode Choice

候補モードの中から、最も適合するものを選ぶ。

代表モード:

- Direct Answer Mode
- Search-Augmented Mode
- File-Grounded Mode
- Comparative Reasoning Mode
- Stepwise Reasoning Mode
- Artifact Generation Mode
- Tool Execution Mode
- Safety Refusal Mode
- Compression Mode
- Validation Mode

モードは単一とは限らず、主モードと補助モードの組み合わせもありうる。

---

3. Depth Setting

選んだモードに応じて、どの程度まで深掘りするかを設定する。

たとえば、

- 直答モードなら浅く速く
- 比較モードなら比較軸を十分立てる
- 検証モードなら根拠の対応づけを厚くする
- 生成モードなら形式完成を優先する

---

4. Resource Profile Binding

各モードで、どの資源を優先利用するかを定める。

例:

- Search-Augmented → Web優先
- File-Grounded → ファイル優先
- Tool Execution → 実行系ツール優先
- Direct Answer → 内部知識優先
- Validation → 根拠抽出優先

---

5. Reasoning Pattern Activation

モードごとに、適した推論パターンを起動する。

例:

- Comparative → 比較軸・差分・推奨
- Stepwise → 分解・段階処理
- Validation → 主張と根拠の対応づけ
- Compression → 主論点抽出と重複除去
- Artifact Generation → テンプレート充填と整形

---

6. Output Bias Setting

出力側で何を重視するかを先に定める。

例:

- Direct Answer → 結論先出し
- Validation → 根拠明示
- Artifact Generation → そのまま使える完成形

- Compression → 最小限で要点維持
- Safety Refusal → 境界説明と代替案

---

7. Mode Switching

処理途中で必要に応じてモードを切り替える。

例:

- 直答で始めたが最新性が必要と判明 → Search-Augmented へ移行
- 調査中に比較依頼を含むと判明 → Comparative を追加
- 外部実行が必要 → Tool Execution へ移行
- 危険領域へ接近 → Safety Refusal に切替

主要モード

A. Direct Answer Mode

内部知識と軽い推論で即答するモード。
高速性と簡潔性を重視する。

B. Search-Augmented Mode

外部検索を前提とするモード。
最新性・確認性を重視する。

C. File-Grounded Mode

添付ファイルや接続ドキュメントを主根拠とするモード。
根拠限定性が高い。

D. Comparative Reasoning Mode

比較軸を立てて差分と推奨を導くモード。

E. Stepwise Reasoning Mode

複雑課題を段階的に分解して処理するモード。

F. Artifact Generation Mode

ノート、文書、コード、表など完成物を作るモード。

G. Tool Execution Mode

メール送信、予定作成、分析実行など外部行動を伴うモード。

H. Safety Refusal Mode

安全境界上の案件で、拒否または安全代替を行うモード。

I. Validation Mode

真偽・妥当性・根拠対応を検証するモード。

J. Compression Mode

長い入力や複雑結果を短く圧縮するモード。

下位構造

A. Mode Detector

必要モードを検出する部分。

B. Mode Chooser

候補から最適モードを選ぶ部分。

C. Profile Binder

深さ・資源・出力傾向を結びつける部分。

D. Switch Controller

途中でのモード切替を管理する部分。

E. Mode State Holder

現在の処理モード状態を保持する部分。

全体構造

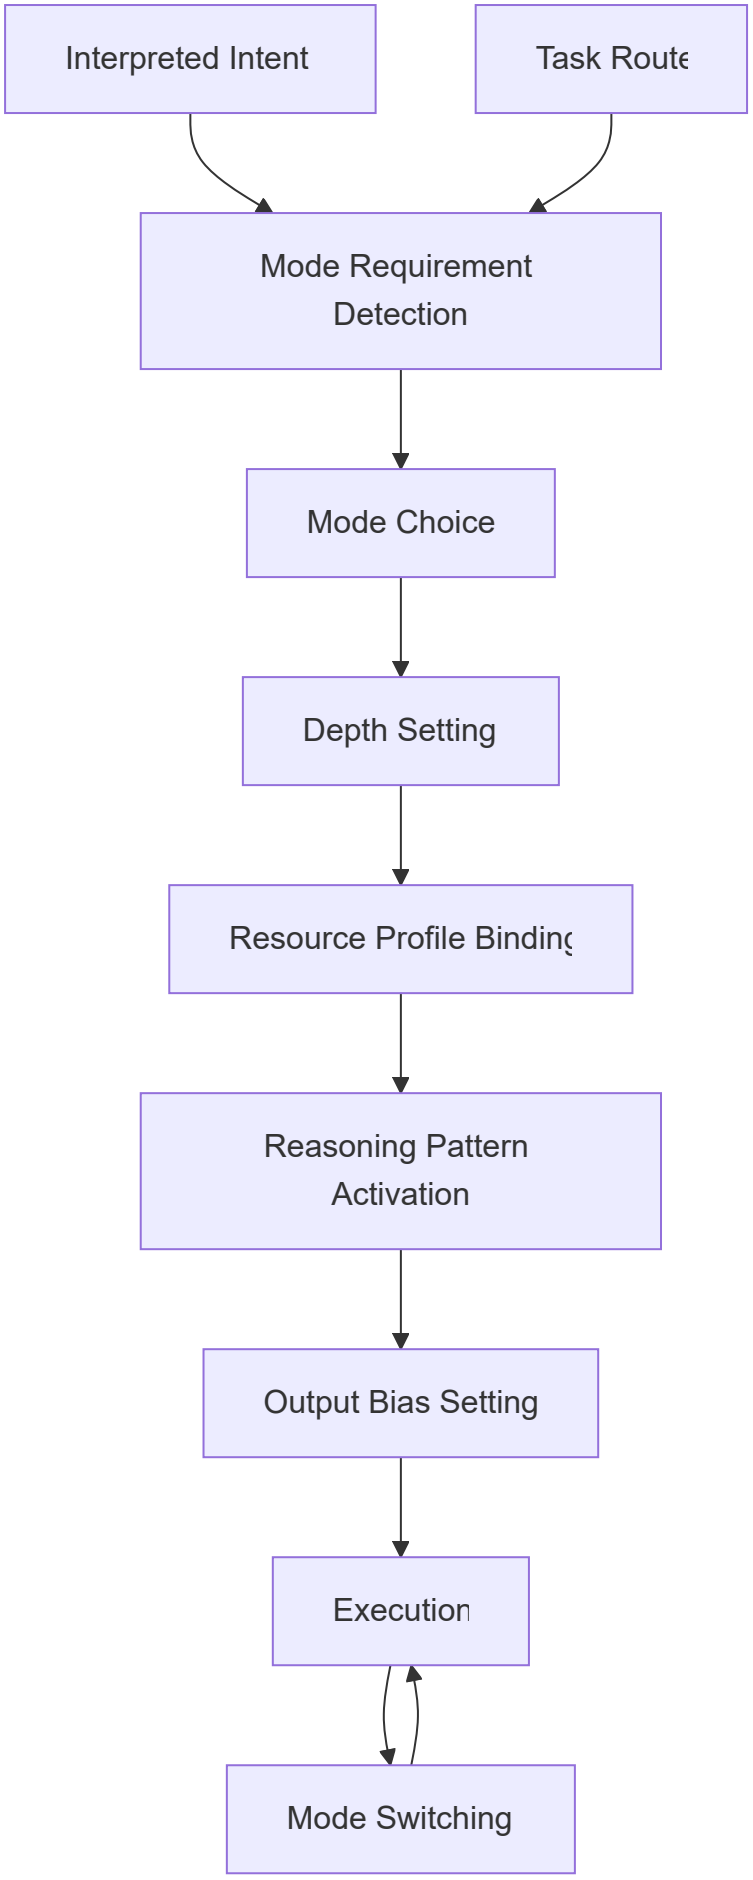
Interpreted Intent
Task Route
Mode Requirement Detection
Mode Choice
Depth Setting
Resource Profile Binding
Reasoning Pattern Activation
Output Bias Setting
Execution
Mode Switching

モード分岐図

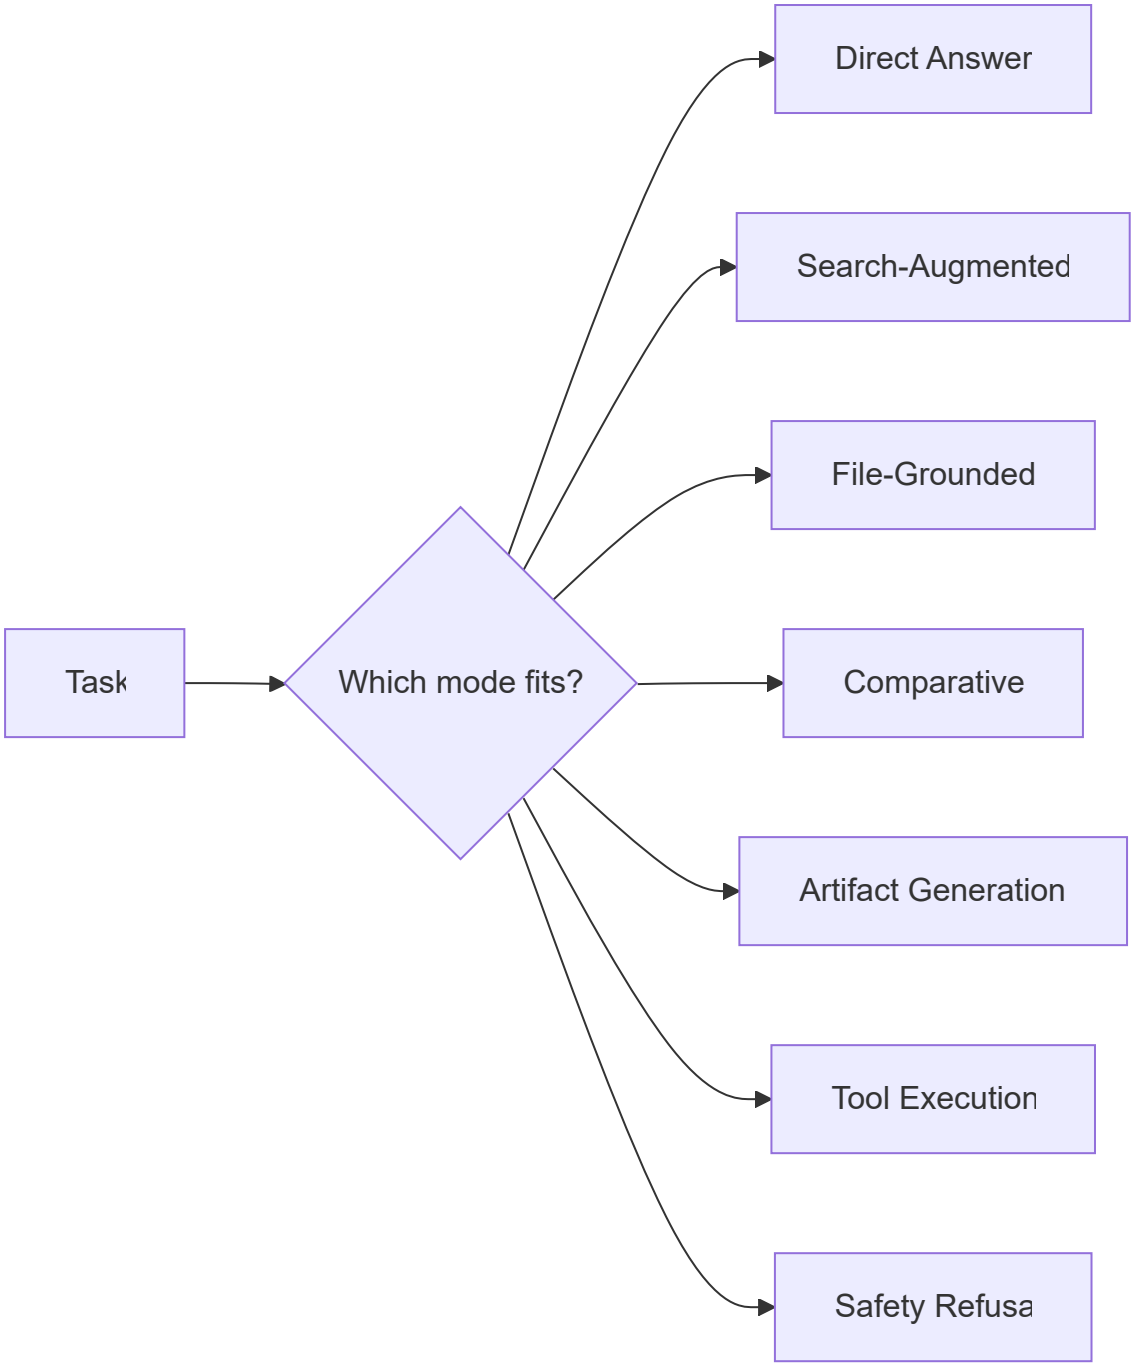

典型例

状況	選ばれやすいモード
一般知識の説明	Direct Answer Mode
最新ニュースの確認	Search-Augmented Mode
PDF要約	File-Grounded Mode + Compression Mode
選択肢比較	Comparative Reasoning Mode
複雑問題の切り分け	Stepwise Reasoning Mode
ノート作成	Artifact Generation Mode

状況	選ばれやすいモード
メール送信	Tool Execution Mode
危険依頼	Safety Refusal Mode

よくある失敗

1. モードを固定しすぎる

何でも同じ調子で処理してしまう。

2. 直答モードのまま進む

検索やファイル根拠が必要なのに切り替わらない。

3. 生成タスクなのに説明モードで動く

完成物ではなく解説ばかり出る。

4. 比較なのに比較モードに入らない

差分や比較軸が立たない。

5. 途中切替がない

新情報で条件が変わっても同じ走り方を続ける。

設計原則

- タスクだけでなく運転形態を選ぶ
- 主モードと補助モードを区別する
- 深さ設定をモードに結びつける
- 資源利用方針もモードに埋め込む
- 処理中の切替を許容する
- 出力傾向まで先に決めておく

位置づけ

Mode Selection は、
処理ラインに対して具体的な運転状態を与える制御構造である。

これが弱いと、

- 直答すべきところで過剰探索し
- 検索すべきところで記憶に頼り
- 生成すべきところで説明に終始し
- 比較すべきところで論点が散る

したがってこの構造は、単なる設定変更ではなく、
LLM の処理品質を場面ごとに最適化する運転モード制御装置である。

関連ノート

- Task Routing
- Goal Framing
- Intent Interpretation
- Tool Orchestration
- Termination Control
- LLM Control Layer Termination Control
- LLM Control Layer
- LLM Control Layer]]
- LLM Control Layer